

PROYECTO PROGRAMADO II
PROGRAMACIÓN PARA ESTADÍSTICA II
UNIVERSIDAD DE COSTA RICA

AUTORES: CYRA COTO, ABIGAIL MURILLO & GUSTAVO JIMÉNEZ

2025

RESUMEN: El presente proyecto tiene como objetivo realizar un análisis descriptivo de las principales variables que tienen que ver con la prevalencia de enfermedades infecciosas tomando como ejemplos de análisis al HIV, TUBERCULOSIS y Dengue en diferentes países alrededor del mundo junto con las características económicas de estos países, para evidenciar el comportamiento de estas variables a través de los últimos años.

Contexto del fenómeno global

En las últimas décadas, el estado de salud de las poblaciones y las condiciones socioeconómicas de los países se han convertido en áreas de interés y análisis para las instituciones internacionales. El gasto público en salud, los niveles de pobreza y la incidencia de enfermedades transmisibles siguen siendo dimensiones clave para evaluar el bienestar social y la capacidad de los Estados para garantizar condiciones de vida adecuadas.

La relación entre estos factores es compleja, un mayor nivel de pobreza suele asociarse con menor acceso a servicios de salud, infraestructuras sanitarias insuficientes y mayores tasas de enfermedades transmisibles. A la vez, el nivel de inversión que un país destina al gasto corriente en salud condiciona su capacidad de prevención, atención y respuesta ante enfermedades como VIH, dengue o tuberculosis.

Analizar estas variables de manera conjunta permite comprender cómo las diferencias en el desarrollo económico influyen en la salud pública y en el bienestar general de las poblaciones. Además, estudiar su evolución en el tiempo nos permite identificar tendencias, desigualdades y posibles áreas críticas que requieren intervención.

Pregunta de investigación

La siguiente pregunta nos permite integrar las dimensiones económicas, sociales y sanitarias para realizar un análisis comparativo entre países a lo largo del tiempo.

¿Cómo ha evolucionado el gasto corriente en salud (% del PIB), la pobreza y la incidencia de las enfermedades transmisibles durante la última década, y de qué

manera varía esta relación entre países con diferentes niveles de desarrollo económico?

Descripción de las bases de datos

Para nuestro análisis se utilizan cinco bases de datos provenientes de fuentes internacionales. Cada una contiene información de múltiples países y años, con tamaños de muestra que permiten realizar comparaciones globales y temporales.

Índice de pobreza

Esta base contiene entre 5,000 y 10,000 observaciones, con información por país y año sobre múltiples indicadores de pobreza. Incluye variables como proporción de población en pobreza, pobreza extrema, brecha de pobreza e indicadores multidimensionales. Su estructura nos permitirá comparar niveles de pobreza entre países y observar su evolución longitudinal.

Gasto corriente en salud (% del PIB)

La base de datos de Gasto Corriente en Salud contiene aproximadamente 270 observaciones y recopila el porcentaje del Producto Interno Bruto (PIB) que cada país destina anualmente al financiamiento del sistema de salud. Este indicador refleja tanto la capacidad de inversión y sostenibilidad del sistema sanitario de cada país, como la prioridad que los gobiernos asignan al sector. Además, permite identificar diferencias importantes entre regiones y niveles de desarrollo económico a lo largo del tiempo.

Bases de enfermedades transmisibles

Las otras tres bases de datos corresponden al número de casos reportados por año en diferentes países para tres enfermedades transmisibles de alto impacto internacional: VIH, dengue y tuberculosis. Cada una contiene alrededor de 2000 observaciones. Estas bases permiten analizar la incidencia anual de estas enfermedades, compararlas entre países y estudiar cómo su comportamiento se relaciona con variables socioeconómicas clave, como la pobreza y el gasto corriente en salud.

Relación entre las bases de datos y pertinencia del análisis

El uso conjunto de estas bases de datos permite construir un análisis integrado entre condiciones económicas, inversión sanitaria y salud pública. La combinación de series de tiempo, múltiples países y tres dimensiones distintas (pobreza, inversión en salud y enfermedades transmisibles) facilita:

- evaluar tendencias a lo largo del tiempo
- comparar diferencias entre países
- explorar relaciones entre las variables
- y observar cómo influyen los niveles de desarrollo económico

Este enfoque es coherente con el propósito del curso y con la creación de un observatorio estadístico interactivo que permita visualizar estas relaciones de manera dinámica.

Metodología

La metodología empleada combina procedimientos de limpieza, integración y análisis descriptivo con el desarrollo de una aplicación interactiva. El objetivo es analizar la evolución del gasto corriente en salud, la pobreza y los casos de dengue en Costa Rica. Las etapas metodológicas conforman un pipeline de datos claro y reproducible.

Pipeline general de datos

Primero se importaron las librerías necesarias (pandas, numpy, json, matplotlib, seaborn y shiny). Luego se cargaron las bases de datos relacionadas con casos de dengue, gasto corriente en salud, indicadores de pobreza y otras variables complementarias.

Se realizó una exploración inicial para identificar la estructura de cada base, revisando columnas, tipos de datos, valores faltantes y duplicados mediante funciones como `df.columns`, `df.info`, `df.head` y `df.isna().sum`. Esto permitió detectar inconsistencias y NA relevantes.

Limpieza de los datos

En esta fase se aplicaron varias acciones:

Eliminación de columnas irrelevantes.

Renombramiento de variables para mantener consistencia entre bases.

Conversión de tipos de datos, especialmente fechas y valores numéricos.

Tratamiento de los datos faltantes (NA): Durante el proceso de limpieza de datos, se identificaron valores faltantes (NA). Algunos de estos valores fueron completados utilizando técnicas apropiadas según la naturaleza de cada variable. Sin embargo, ciertos NA se mantuvieron sin rellenar deliberadamente, con el fin de evitar introducir sesgos que pudieran alterar la validez del análisis.

Eliminación de duplicados y corrección de errores detectados.

Estas decisiones permitieron mantener la fidelidad estadística de los datos originales.

Transformación e integración de las bases

Una vez limpiadas, las bases fueron integradas mediante merges usando como clave el año. El DataFrame resultante incorporó casos de dengue, gasto corriente en salud como porcentaje del PIB, indicadores de pobreza y variables derivadas para análisis comparativo. Esto permitió observar relaciones entre los principales indicadores en una sola estructura integrada.

Análisis exploratorio

Se realizaron estadísticas descriptivas como medias, máximos, mínimos y distribuciones, además de pruebas de correlación utilizando el coeficiente de Pearson. También se generaron visualizaciones como series temporales, gráficos de dispersión y comparaciones entre indicadores sociales, económicos y epidemiológicos. Estas herramientas permitieron identificar tendencias y variaciones relevantes.

Simulaciones

Para comprender la variabilidad de los casos de dengue, se aplicó una simulación basada en la distribución Poisson. Esta incluyó el cálculo de la media observada, la generación de valores simulados y la comparación entre los datos reales y los simulados. La simulación permitió aproximar el comportamiento esperado bajo un modelo probabilístico básico.

Desarrollo de la aplicación interactiva Shiny

Como complemento del análisis, se desarrolló una aplicación en Shiny para Python que permite visualizar interactivamente los gráficos y la base integrada. Incluye carga del DataFrame final, interfaz con elementos de selección, gráficos generados dinámicamente mediante `render.plot` y configuración con Ngrok para acceso externo. El prototipo es funcional, aunque aún puede ampliarse.

Desarrollo de la aplicación interactiva Shiny

Como complemento del análisis, se desarrolló una aplicación en Shiny para Python que permite visualizar interactivamente los gráficos y la base integrada. Incluye carga del DataFrame final, interfaz con elementos de selección, gráficos generados dinámicamente mediante `render.plot` y configuración con Ngrok para acceso externo. El prototipo es funcional, aunque aún puede ampliarse.

Principales hallazgos descriptivos

Evolución del dengue

Los casos de dengue muestran una variabilidad marcada a lo largo del periodo analizado. Se observa que hay años con incrementos muy significativos, lo que refleja la sensibilidad del dengue a factores climáticos y ambientales. En particular, se identifican picos que podrían estar asociados a épocas de lluvia o a condiciones favorables para la proliferación

del mosquito transmisor. Esta variabilidad evidencia que el dengue es un fenómeno muy dinámico y dependiente del entorno.

Gasto corriente en salud

El gasto corriente en salud, expresado como porcentaje del PIB, presenta una tendencia fluctuante a lo largo de los años. Si bien no muestra incrementos bruscos, sí refleja variaciones moderadas. A partir del análisis, no se observa una relación directa e inmediata entre el gasto en salud y los casos de dengue, lo que indica que la inversión en salud no necesariamente impacta de forma rápida en la incidencia de enfermedades vectoriales, ya que estas dependen también de múltiples factores externos.

Pobreza y dengue

Los indicadores de pobreza total y pobreza extrema se mantienen relativamente estables durante la mayoría de los años, con pequeñas variaciones que no parecen seguir un patrón estrechamente relacionado con el comportamiento del dengue. Este hallazgo coincide con la idea de que, si bien la pobreza incrementa la vulnerabilidad, la incidencia del dengue depende más de factores ecológicos (lluvias, clima, presencia del vector) que de factores socioeconómicos por sí solos.

Correlaciones entre variables

El análisis de correlación de Pearson muestra relaciones débiles o moderadas entre los indicadores analizados. No se evidencia una correlación fuerte entre pobreza, gasto en salud y casos de dengue. Esto sugiere que los fenómenos bajo estudio son multifactoriales y que ninguna de las variables por sí sola explica de manera clara el comportamiento del dengue. El dengue se ve influido por factores externos que no fueron incluidos en el modelo, como clima, temperatura o acciones de control vectorial.

Resultados de la simulación

La simulación realizada con la distribución Poisson generó valores que se asemejan al promedio de casos de dengue observado en los datos reales. Esto indica que, bajo una perspectiva estadística básica, el dengue puede modelarse como un proceso aleatorio dependiente de su media anual. Sin embargo, la simulación no captura patrones temporales complejos ni factores externos, por lo que su utilidad es introductoria y complementaria al análisis descriptivo.

Limitaciones del análisis

Disponibilidad y calidad de datos. Algunas bases presentaron valores faltantes importantes. En ciertos casos se decidió no rellenar NA para evitar sesgos, lo cual reduce la cantidad de datos analizables pero aumenta la validez del análisis.

Heterogeneidad de fuentes. Las bases provienen de instituciones con definiciones y formatos distintos, lo que dificulta su integración completa.

Granularidad anual. La falta de datos mensuales o semanales limita la posibilidad de estudiar el comportamiento estacional del dengue.

Factores ambientales no incluidos. No se incorporaron variables como precipitación o temperatura, que explican gran parte de la variación de los casos de dengue.

Simulación simplificada. El modelo Poisson no incorpora autocorrelación temporal o elementos externos a un fenómeno que influyen en él, pero que no forman parte del sistema que se está analizando.

Aplicación Shiny en etapa inicial. Aunque funcional, aún carece de controles avanzados, más filtros e informes automáticos.

Referencias Bibliográficas de las bases de datos

1. Base Dengue 1 – WHO World Health Organization. (2025). Dengue global data [Dataset]. https://worldhealthorg.shinyapps.io/dengue_global/ World Health Organization. (2025). Dengue global data [Dataset]. Retrieved November 12, 2025, from https://worldhealthorg.shinyapps.io/dengue_global/
2. Base Dengue 2 – OpenDengue OpenDengue. (2025). National extract V1.3 [Dataset]. <https://opendengue.org/>
3. Base Tuberculosis – Our World in Data Our World in Data. (2025). Number of tuberculosis cases [Dataset]. <https://ourworldindata.org/grapher/number-of-tuberculosis-cases>
4. Base HIV – UNAIDS UNAIDS. (2025). HIV estimates with uncertainty bounds, 1990–present [Dataset]. https://www.unaids.org/en/resources/documents/2025/HIV_estimates_with_uncertainty_bounds_1990-present
5. Base Gasto en Salud (% PIB) – Banco Mundial World Bank. (2025). Current health expenditure (% of GDP) [Dataset]. <https://datos.bancomundial.org/indicador/SH.XPD.CHEX.GD.ZS>

6. Base Índice de Pobreza – Banco Mundial (PIP) World Bank. (2025). Global poverty index [Dataset]. <https://pip.worldbank.org/>